# تخمین سن مغز از روی تصویر خام، و آنچه در این مسیر آموختیم

گزارش پیشین با یک محدودیت صریح به پایان رسید: تمام آزمایش‌های آن بر حجم‌های از پیش استخراج‌شده‌ی FreeSurfer استوار بود و هرگز خودِ تصویر به مدل داده نشد. این گزارش همان شکاف را می‌بندد. در بخش نخست توضیح می‌دهیم که چرا این پرسش یک کنجکاوی فنی نیست بلکه شرط لازم هر استفاده‌ی عملی است، و چرا صورت‌بندی رایج آن — «تصویر بهتر است یا حجم‌ها؟» — از اساس نادرست است. در بخش‌های دوم تا پنجم، پنج خانواده‌ی آزمایش را گزارش می‌کنیم که همگی روی داده‌ی واقعی و با تقسیم در سطح فرد اجرا شده‌اند: دستور کلاسیک روی پیکسل خام، شبکه‌های کانولوشنی، گلوگاه تشریحی، مدل‌های از پیش آموزش‌دیده، و سنجش حساسیت طولی. در بخش ششم خطاهایی را که در کار خودمان یافتیم و تصحیح کردیم می‌آوریم، زیرا دو مورد از آن‌ها اعدادی تولید کرده بودند که کاملاً باورپذیر و کاملاً نادرست بودند. در پایان، جمع‌بندی می‌کنیم که کدام نتیجه‌ی گزارش سوم پس از این آزمایش‌ها باید بازنویسی شود و مسیر پیشنهادی برای ادامه چیست.

---

## بخش ۱: چرا پرسش «تصویر یا حجم؟» از اساس نادرست است

در پایان گزارش سوم، محدودیت کار را چنین نوشتیم که هرگز از خود تصویر استفاده نکرده‌ایم. صورت‌بندی طبیعی برای رفع این محدودیت آن است که تصویر را به مدل بدهیم و ببینیم آیا از حجم‌ها بهتر عمل می‌کند یا نه. اما این صورت‌بندی، هرچند طبیعی به‌نظر می‌رسد، پرسشی بی‌معنا می‌سازد.

### ۱-۱ حجم‌ها خودشان از همان تصویر ساخته شده‌اند

شش عددی که در سراسر گزارش سوم به‌عنوان ورودی مدل به کار رفتند — حجم هیپوکامپ، قشر آنتورینال، شکنج دوکی، گیجگاهی میانی، بطن‌ها و کل مغز — داده‌ی مستقلی نیستند. این‌ها خروجی نرم‌افزار FreeSurferاند و FreeSurfer آن‌ها را از روی همان تصویر MRI محاسبه می‌کند. بنابراین ادعای «تصویر اطلاعات کمتری از حجم‌ها دارد» از نظر منطقی ناممکن است: هر چیزی که در حجم‌ها هست، پیش‌تر در تصویر بوده است.

اگر مدلی که تصویر را می‌بیند ضعیف‌تر از مدلی عمل کند که حجم‌ها را می‌بیند، این موضوع چیزی درباره‌ی محتوای اطلاعاتی تصویر نمی‌گوید. تنها چیزی که می‌گوید این است که مدل ما نتوانسته آن اطلاعات را استخراج کند — یعنی مسأله در **بازنمایی** است، نه در **داده**. این تمایز، ستون فقرات کل این گزارش است.

## ۱-۲ در عمل، جدولی وجود ندارد؛ فقط یک اسکن وجود دارد

دلیل دوم عملی است. اگر روزی بخواهیم از این کار چیزی بسازیم که به درد بخورد، آنچه در اختیار خواهیم داشت یک تصویر MRI از بیمار است، نه یک جدول آماده‌ی FreeSurfer. اجرای FreeSurfer روی هر اسکن چندین ساعت پردازش می‌برد، به نصب و تنظیم نیاز دارد، و در بسیاری از مراکز درمانی اصلاً بخشی از روال کار نیست.

پس پرسش درست این نیست که کدام‌یک بهتر است. پرسش درست این است:

> **چه مقدار از سیگنالی که با حجم‌های واقعی به‌دست می‌آید، از روی پیکسل خام قابل بازیابی است؟**

## ۱-۳ نتیجه‌ی این بازنگری: حجم‌های واقعی از رقیب به سقف تبدیل می‌شوند

این بازنگری یک پیامد مستقیم در نحوه‌ی گزارش نتایج دارد. در تمام آزمایش‌های این گزارش، مدلی که حجم‌های واقعی FreeSurfer را می‌بیند همچنان اجرا و گزارش می‌شود، اما **نه به‌عنوان رقیب، بلکه به‌عنوان سقف**. این عدد صرفاً به ما می‌گوید چه مقدار فاصله باقی مانده است.

بر همین اساس، معیار اصلی گزارش نسبت ساده‌ی دو AUC نیست، بلکه **درصد سیگنالِ بالای شانس** است:

> بازیابی = (AUC مدل تصویری − ۰٫۵) ÷ (AUC سقف − ۰٫۵)

دلیل این انتخاب در بخش ۶ توضیح داده می‌شود؛ آنجا نشان خواهیم داد که نسبت ساده‌ی دو AUC عددی گمراه‌کننده تولید می‌کند، زیرا کفِ AUC صفر نیست بلکه ۰٫۵ است.

---

## بخش ۲: داده و روش

### ۲–۱ داده‌ها

از دو دیتاست تصویری استفاده کردیم که هر دو آزادانه در دسترس‌اند:

| دیتاست | نوع تصویر | حجم | ترکیب |
|---|---|---|---|
| OASIS-1 | برش‌های دوبعدی محوری | ۸۶٬۴۳۷ برش از ۳۴۷ فرد | ۲۶۶ نفر سالم (۱۸ تا ۹۴ سال)، ۸۱ نفر دارای اختلال شناختی |
| ADNI | حجم سه‌بعدی $128^3$ | ۳٬۲۸۶ اسکن از ۱٬۱۳۲ فرد | در اسکن پایه: ۴۴۱ سالم، ۴۳۹ MCI، ۱۸۰ دمانس |

دو ویژگی این داده‌ها برای ما ارزش خاصی داشت. نخست آنکه هر فرد در OASIS-1 **سه تا چهار اسکن تکراری در یک جلسه** دارد؛ یعنی همان مغز، با فاصله‌ی چند دقیقه. هر تفاوتی که میان این اسکن‌ها دیده شود لزوماً نویز اندازه‌گیری است و نه زیست‌شناسی. دوم آنکه بخش بزرگی از افراد ADNI اسکن‌های پیگیری دارند، که امکان محاسبه‌ی **سرعت تغییر** را از روی تصویر فراهم می‌کند — همان کمیتی که در گزارش سوم مهم‌ترین یافته بود.

یک نکته‌ی فنی که ذکرش لازم است: آرشیو فشرده‌ی ADNI حدود شش گیگابایت است، اما پس از باز شدن به **۳۳٫۶ گیگابایت** می‌رسد، چون حدود ۹۳ درصد هر حجم، پس‌زمینه‌ی صفر است. فضای کافی برای این کار وجود نداشت، بنابراین هر حجم مستقیماً از داخل آرشیو خوانده، بلافاصله کوچک شد و از حافظه بیرون رفت؛ بدون آنکه هرگز روی دیسک نوشته شود.

پیش از هر آزمایشی، صحت اتصال داده‌ها را بررسی کردیم. هر ۸۶٬۴۳۷ برش OASIS از روی نام فایل به جدول دموگرافیک وصل شد و نرخ تطابق ۱۰۰ درصد بود. افزون بر این، برچسب پوشه‌هایی که تصاویر در آن‌ها قرار داشتند دقیقاً با مقدار CDR در جدول هم‌خوانی داشت. این آزمون ساده تأیید می‌کند که آرشیو تصاویر و جدول بالینی واقعاً یک مجموعه‌ی واحد را توصیف می‌کنند.

## ۲-۲ روش

ساختار دو مرحله‌ای گزارش سوم **بدون هیچ تغییری** حفظ شد: مرحله‌ی نخست یک مدل رگرسیون که فقط روی افراد سالم آموزش می‌بیند و سن تقویمی را پیش‌بینی می‌کند، و مرحله‌ی دوم یک مدل طبقه‌بندی. تنها چیزی که در این گزارش تغییر می‌کند **ورودی مرحله‌ی نخست** است. این قید عمدی است: اگر همزمان هم ورودی و هم ساختار مدل عوض شود، دیگر نمی‌توان فهمید تفاوت نتایج از کدام‌یک ناشی شده است.

سه نکته‌ی روش‌شناختی رعایت شد که هر سه اهمیت زیادی دارند:

**نخست، تقسیم داده در سطح فرد.** هر فرد در OASIS حدود دویست برش و در ADNI چند اسکن پیگیری دارد. اگر تقسیم آموزش و آزمون در سطح برش یا در سطح اسکن انجام شود، همان مغز هم در آموزش و هم در آزمون حاضر می‌شود و مدل می‌تواند به‌جای یادگیری بیماری، صرفاً فرد را بازشناسی کند. این دقیقاً همان دلیلی است که برخی مقالات منتشرشده روی این دیتاست دقت‌های باورنکردنی گزارش می‌کنند. در تمام آزمایش‌های این گزارش، تقسیم در سطح فرد انجام شده است.

**دوم، نرمال‌سازی شدت با صدک ۹۵ و نه با میانگین.** روشنایی تصاویر MRI میان اسکن‌ها یکسان نیست و باید نرمال شود، وگرنه مدل به‌جای آناتومی، بهره‌ی دستگاه را می‌خواند. اما اینکه بر چه عددی تقسیم کنیم اهمیت بسیار زیادی دارد. انتخاب بدیهی، یعنی میانگین پیکسل‌های غیرپس‌زمینه، نادرست است: آتروفی بافت روشن را با مایع مغزی‌نخاعی تیره جایگزین می‌کند، پس همین میانگین خودش یکی از قوی‌ترین پیش‌بین‌های بیماری است ( = AUC ۰٫۳۹۸) و تقسیم بر آن، سیگنال را حذف می‌کند. این را مستقیماً اندازه گرفتیم: یک ویژگی دست‌ساز که نسبت پیکسل‌های تیره را می‌شمارد، پیش از نرمال‌سازی ۰٫۶۰۷ = AUC داشت و پس از تقسیم بر میانگین به ۰٫۵۲۳ سقوط کرد. در مقابل، صدک ۹۵ که ماده‌ی سفید را دنبال می‌کند تقریباً خنثی است (۰٫۵۱۲ = AUC) و در تمام آزمایش‌ها از همان استفاده شد.

**سوم، سن در زمان اسکن، نه سن پایه.** ستون سن در جدول ADNIMERGE سنِ فرد در **نخستین** مراجعه است و در تمام مراجعات بعدی همان عدد تکرار می‌شود. اگر این ستون برای اسکن‌های پیگیری به‌کار رود، سن فرد تا ده سال کمتر از واقع ثبت می‌شود و شکاف سن مغز به‌طور مصنوعی بزرگ می‌گردد. در تمام محاسبات، سن هر اسکن برابر با سن پایه به‌علاوه‌ی فاصله‌ی زمانی آن مراجعه در نظر گرفته شده است.

## بخش ۳: دستور کلاسیک روی پیکسل خام شکست می‌خورد — و علت آن کمبود اطلاعات نیست

نخستین کاری که انجام دادیم ساده‌ترین کار ممکن بود: همان دستوری که Franke و همکاران در سال ۲۰۱۰ معرفی کردند و تا امروز مرجع این حوزه است. در آن دستور، تصویر کوچک می‌شود، با تحلیل مؤلفه‌های اصلی (PCA) به چند ده بُعد کاهش می‌یابد، و یک مدل خطی از روی همان مؤلفه‌ها سن را پیش‌بینی می‌کند.

### ۳-۱ نتیجه روی OASIS: شکست کامل

مدل و ساختار دقیقاً همان چیزی است که در گزارش سوم به‌کار رفت؛ تنها ورودی عوض شده است.

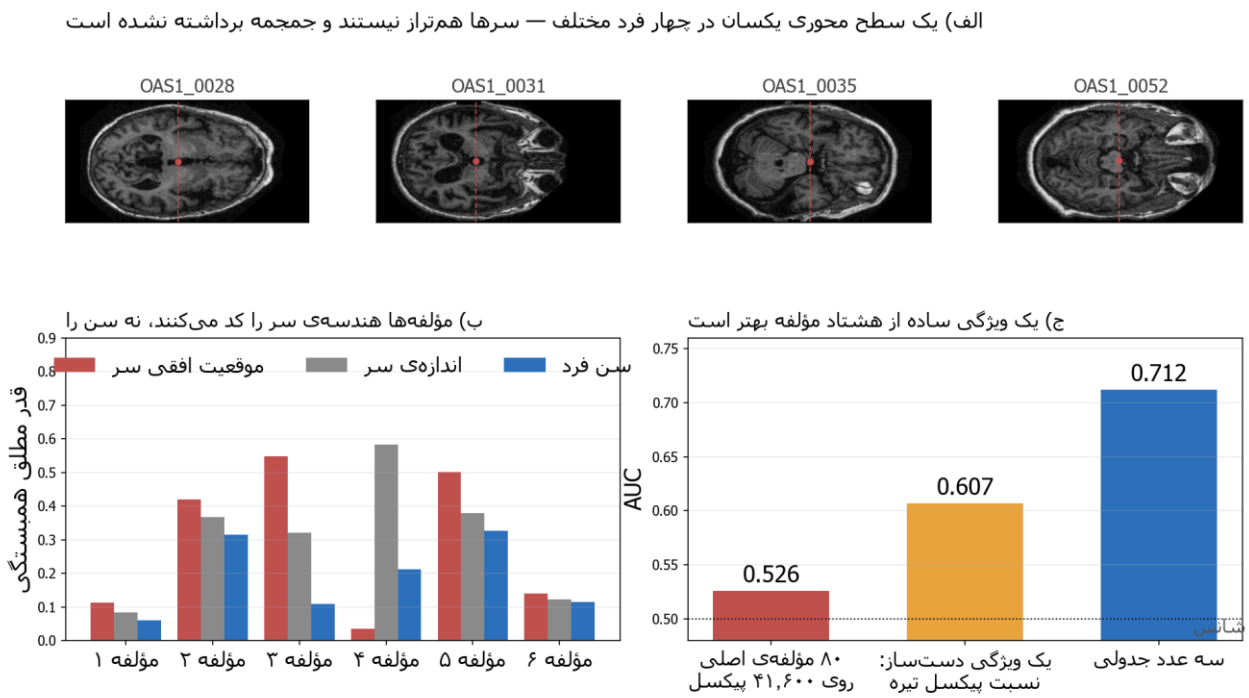
| ورودی مرحله‌ی نخست | خطای تخمین سن (۶۰ سال به بالا) | AUC از شکاف سن | AUC مدل مستقیم |
|---|---|---|---|
| سه عدد جدولی (nWBV، eTIV، جنسیت) | **۱۱٫۰ سال** | **۰٫۷۲۹** | ۰٫۷۱۲ |
| تصویر: ۴۱٬۶۰۰ پیکسل → ۸۰ مؤلفه | ۱۵٫۸ سال | ۰٫۴۳۲ | ۰٫۵۲۶ |
| هر دو با هم | — | ۰٫۴۳۳ | ۰٫۶۴۹ |

عدد ۰٫۴۳۲ نه‌تنها ضعیف است، بلکه **پایین‌تر از شانس** است. سه عدد ساده‌ی جدولی، ۴۱٬۶۰۰ پیکسل را با اختلاف زیادی شکست می‌دهند. اگر کار را همین‌جا متوقف می‌کردیم، نتیجه‌گیری طبیعی این بود که تصویر در این مقیاس بی‌فایده است.

## ۳-۲ چرا شکست خورد؟ یک ویژگی دست‌ساز از هشتاد مؤلفه بهتر عمل می‌کند

پیش از پذیرفتن آن نتیجه‌گیری، آزمون ساده‌ای انجام دادیم. یک ویژگی کاملاً دست‌ساز تعریف کردیم: نسبت پیکسل‌های تیره (یعنی مایع مغزی‌نخاعی) به کل پیکسل‌های داخل جمجمه. این ویژگی هیچ یادگیری‌ای در خود ندارد و در یک خط کد محاسبه می‌شود.

| روش | AUC |
|---|---|
| یک ویژگی دست‌ساز: نسبت پیکسل تیره | **۰٫۶۰۷** |
| ۸۰ مؤلفه‌ی اصلی روی ۴۱٬۶۰۰ پیکسل | ۰٫۵۲۶ |




**شکل ۱ — چرا تحلیل مؤلفه‌های اصلی روی پیکسل خام شکست می‌خورد. الف) یک سطح محوری یکسان در چهار فرد مختلف؛ خط‌چین قرمز مرکز ثقل سر را نشان می‌دهد و پیداست که سرها هم‌تراز نیستند و جمجمه نیز برداشته نشده است. ب) قدر مطلق همبستگی هر مؤلفه با هندسه‌ی سر و با سن. ج) پیامد این وضعیت در AUC.**

اطلاعات در تصویر هست؛ مشکل این است که PCA آن را پیدا نمی‌کند. برای فهمیدن علت، بررسی کردیم که مؤلفه‌های اصلی در عمل چه چیزی را کد می‌کنند:

| همبستگی مؤلفه‌های اصلی با … | بیشینه در میان شش مؤلفه‌ی نخست |
|---|---|
| موقعیت افقی سر در کادر | ۰٫۵۵ |
| اندازه‌ی سر | ۰٫۵۸ |
| سن فرد | ۰٫۳۳ |

یعنی مؤلفه‌ها به‌جای توصیف مغز، توصیف می‌کنند که **سر کجای تصویر قرار گرفته است و چقدر بزرگ است**. شکل ۱ این وضعیت را نشان می‌دهد. دقت کنید که این الگو از مؤلفه‌ی دوم آغاز می‌شود؛ مؤلفه‌ی نخست با هیچ‌یک از سه کمیت همبستگی معناداری ندارد (کمتر از ۰٫۱۲) و ظاهراً تفاوت‌های کلی روشنایی و کنتراست را کد می‌کند. دلیلش روشن است: این برش‌ها به یک قالب مرجع مشترک ثبت (register) نشده‌اند. دستور Franke این مرحله‌ی ثبت را به‌عنوان پیش‌فرض در خود دارد؛ بدون آن، پیکسل شماره‌ی (i, j) در دو فرد مختلف اصلاً به یک ناحیه‌ی آناتومیک اشاره نمی‌کند و PCA ناچار است ظرفیت خود را صرف توصیف موقعیت سر کند.

این نکته را با یک آزمون دیگر هم تأیید کردیم: یک هم‌ترازسازی خام (انتقال مرکز ثقل و یکسان‌سازی اندازه) AUC مدل خطی را از ۰٫۴۰۷ به ۰٫۵۳۶ رساند — بهبودی واقعی، هرچند هنوز بسیار دور از عدد جدولی.

## ۳-۳ همان نتیجه در ADNI، با نمونه‌ی بزرگ‌تر و تصاویر ثبت‌شده

ممکن است اشکال بالا را به کیفیت پایین داده‌ی OASIS نسبت داد. بنابراین همان آزمایش را روی ADNI تکرار کردیم که حجم‌های سه‌بعدی ثبت‌شده و جمجمه‌برداشته دارد — یعنی همان پیش‌شرطی که دستور Franke نیاز دارد.

| ورودی | خطای سن | AUC شکاف (AD در برابر سالم) | مدل مستقیم |
|---|---|---|---|
| حجم‌ها + ICV + جنسیت | **۴٫۳ سال** | ۰٫۹۲۳ | **۰٫۹۵۲** |
| PCA وکسلی روی تصویر | ۴٫۹ سال | ۰٫۶۲۷ | ۰٫۶۴۸ |
| هر دو با هم | ۴٫۵ سال | ۰٫۸۷۳ | ۰٫۹۳۱ |

دو نتیجه از این جدول بیرون می‌آید. نخست آنکه با ثبت درست تصاویر، وضع تصویر بهتر می‌شود (۰٫۶۴۸ در برابر ۰٫۵۲۶ در OASIS) اما همچنان فاصله‌ی زیادی با سقف دارد. دوم و مهم‌تر آنکه **افزودن تصویر به حجم‌ها نتیجه را بدتر می‌کند**: ۰٫۹۳۱ در برابر ۰٫۹۵۲، یعنی ۰٫۰۲۱− . همین الگو در تشخیص MCI نیز تکرار شد (۰٫۰۴۶−).

در آن مرحله از کار، نتیجه‌گیری ما این بود که در این مقیاس، تصویر خام نه بهتر از حجم‌هاست و نه چیزی به آن‌ها می‌افزاید. بخش‌های بعدی نشان می‌دهند که این نتیجه‌گیری، هرچند از نظر عددی درست بود، **علت را اشتباه تشخیص داده بود**.

---

# بخش ۴: گلوگاه تشریحی — به‌جای آنکه شبکه بازنمایی را کشف کند، آن را به او بیاموزیم

---

نتیجه‌ی بخش پیش یک تناقض ظاهری بر جای گذاشت. از یک سو، حجم‌ها از روی همان تصویر محاسبه می‌شوند و بنابراین تصویر نمی‌تواند اطلاعات کمتری داشته باشد. از سوی دیگر، هر مدلی که تصویر را می‌دید از مدلی که حجم‌ها را می‌دید شکست می‌خورد. تنها توضیح ممکن این است که مدل نمی‌تواند آن اطلاعات را **استخراج** کند.

## ۴-۱ ایده

FreeSurfer برای رسیدن به آن شش عدد، دهه‌ها دانش آناتومیک انباشته را به‌کار می‌گیرد: اطلس‌های احتمالاتی، مدل‌های شکل، و قواعدی که متخصصان طی سال‌ها تدوین کرده‌اند. انتظار اینکه یک شبکه‌ی عصبی با حدود هزار نفر داده، همان بازنمایی را از صفر **کشف** کند انتظار نامعقولی است.

پس آن را کشف نکنیم؛ مستقیماً به شبکه بیاموزیم. شبکه را آموزش می‌دهیم تا از روی تصویر، همان هفت عدد را تولید کند؛ سپس همان اعداد پیش‌بینی‌شده را به خط لوله‌ی دو مرحله‌ای همیشگی می‌دهیم:

تصویر ← هفت عدد آناتومیک ← سن ← شکاف ← بیماری

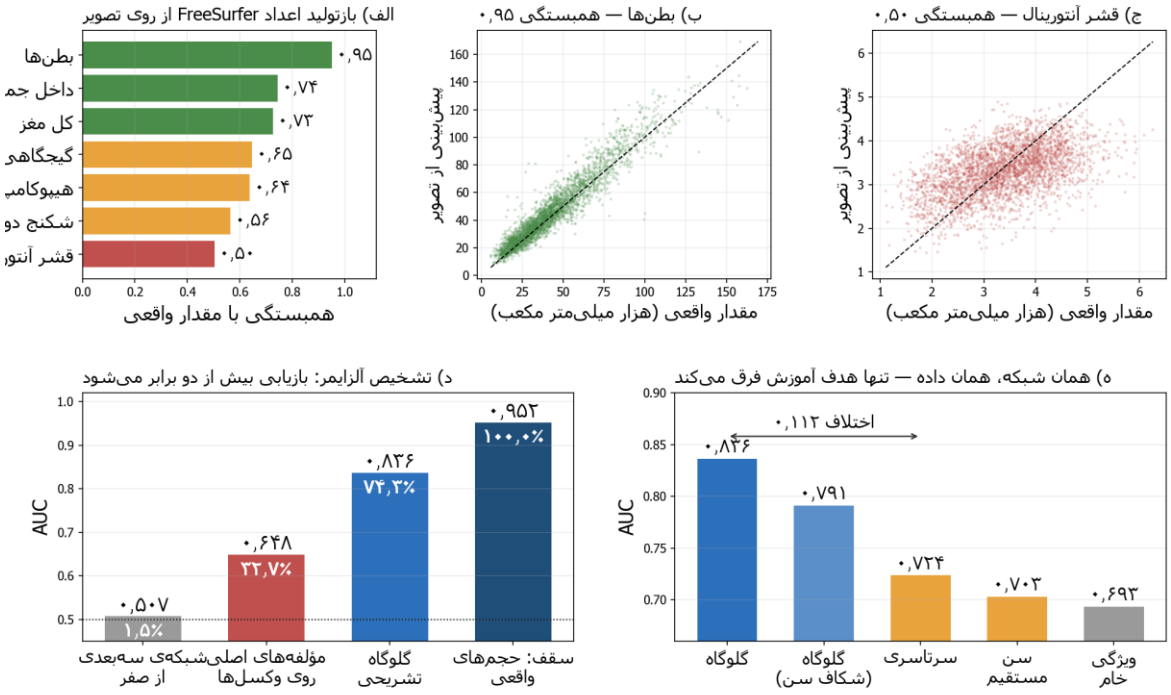
در این طرح، حجم‌ها نقش یک **گلوگاه معنادار** را بازی می‌کنند؛ یعنی شبکه مجبور است اطلاعات تصویر را از مجرایی عبور دهد که از پیش می‌دانیم با بیماری مرتبط است.

## ۴-۲ کنترل نشت اطلاعات

در این طرح یک خطر جدی وجود دارد که باید صریح ذکر شود. اگر شبکه‌ای که حجم‌های یک فرد را پیش‌بینی می‌کند، همان فرد را در آموزش دیده باشد، تمام نتایج پایین‌دستی بی‌اعتبار می‌شوند. بنابراین تقسیم پنج‌تایی بیرونی در سطح **فرد** انجام شد و هر عددی که برای یک فرد تولید می‌شود، از شبکه‌ای می‌آید که آن فرد را هرگز ندیده است.

نکته‌ی دیگر آنکه پیش‌بینی آناتومی ربطی به تشخیص ندارد؛ حجم هیپوکامپ یک کمیت فیزیکی است، نه یک برچسب بالینی. بنابراین مرحله‌ی نخست روی **همه‌ی افراد** آموزش داده شد، نه فقط سالم‌ها. مدل سن، طبق روال همیشگی، همچنان فقط روی افراد سالم برازش می‌شود.

## ۴-۳ آیا تصویر می‌تواند اعداد FreeSurfer را بازتولید کند؟




**شکل ۲ — گلوگاه تشریحی. الف) میزان بازتولید هر عدد FreeSurfer از روی تصویر. ب و ج) بهترین و بدترین حالت به‌صورت نمودار پراکندگی؛ خطچین، تطابق کامل را نشان می‌دهد. د) نردبان بازیابی در تشخیص آلزایمر؛ درصدها سهم سیگنالِ بالای شانس‌اند. ه) چهار مسیر مختلف با شبکه و داده‌ی یکسان، که تنها در هدف آموزش تفاوت دارند.**

| ناحیه | همبستگی پیش‌بینی با مقدار واقعی |
|---|---|

| | |
|---|---|
| بطن‌ها | **۰٫۹۵۱** |
| حجم داخل جمجمه | ۰٫۷۴۴ |
| کل مغز | ۰٫۷۲۶ |
| گیجگاهی میانی | ۰٫۶۴۶ |
| هیپوکامپ | ۰٫۶۳۷ |
| شکنج دوکی | ۰٫۵۶۵ |
| قشر آنتورینال | **۰٫۵۰۴** |

الگوی این جدول کاملاً قابل انتظار است و همین آن را باورپذیر می‌کند: ساختارهای بزرگ و پرکنتراست به‌خوبی بازتولید می‌شوند و ساختارهای کوچک و مرزمبهم به‌سختی. اما همین الگو یک مشکل جدی در خود دارد. **قشر آنتورینال، که آسیب آلزایمر از آنجا آغاز می‌شود، بدترین عدد جدول است.** یعنی گلوگاه دقیقاً در حساس‌ترین ناحیه ضعیف‌ترین عملکرد را دارد. در بخش ۶ خواهیم دید که این ضعف پیامدهای جدی‌تری هم دارد.

## ۴-۴ نتیجه‌ی پایین‌دستی: بازیابی بیش از دو برابر می‌شود

| روش | AUC در تشخیص آلزایمر | درصد سیگنال بازیابی‌شده |
|---|---|---|
| شبکه‌ی سه‌بعدی آموزش‌دیده از صفر | ۰٫۵۰۷ | ٪۱٫۵ |
| PCA وکسلی (بخش ۳) | ۰٫۶۴۸ | ٪۳۲٫۷ |
| **گلوگاه تشریحی** | **۰٫۸۳۶** | **٪۷۴٫۳** |
| سقف: حجم‌های واقعی FreeSurfer | ۰٫۹۵۲ | ٪۱۰۰ |

همین الگو در تشخیص MCI نیز تکرار شد: ۰٫۷۰۰ در برابر سقف ۰٫۷۹۱.

## ۴-۵ چرا گلوگاه کار می‌کند؟ چگالی نظارت، نه معماری

برای آنکه بدانیم این بهبود از خودِ ایده‌ی گلوگاه می‌آید یا صرفاً از استفاده از یک شبکه‌ی بهتر، چهار مسیر مختلف را با **معماری یکسان و داده‌ی یکسان** اجرا کردیم و تنها چیزی که میان آن‌ها فرق می‌کرد، هدف آموزش بود.

| مسیر | آنچه شبکه یاد می‌گیرد | AUC |
|---|---|---|
| گلوگاه | تصویر ⟵ هفت عدد آناتومیک | **۰٫۸۳۶** |
| گلوگاه، از طریق شکاف سن | همان، ولی فشرده در یک عدد | ۰٫۷۹۱ |
| سرتاسری | تصویر ⟵ برچسب بیماری | ۰٫۷۲۴ |
| سن مستقیم | تصویر ⟵ سن | ۰٫۷۰۳ |
| ویژگی خام | ۲٬۰۴۸ ویژگی شبکه + سن | ۰٫۶۹۳ |

اختلاف میان مسیر نخست و مسیر سرتاسری ۰٫۱۱۲ است، در حالی که شبکه، داده و تقسیم‌بندی در هر دو یکسان‌اند. توضیح این اختلاف در **مقدار نظارتی** است که هر مسیر دریافت می‌کند: مسیر سرتاسری حدود پانصد برچسب دوحالته می‌بیند، در حالی که گلوگاه ۳٬۲۸۶ اسکن ضربدر هفت عدد حقیقی در اختیار دارد. هر عدد حقیقی اطلاعات بسیار بیشتری از یک برچسب صفر و یک حمل می‌کند.

این ترتیب در دو اجرای مستقل با بودجه‌های آموزشی متفاوت عیناً تکرار شد، بنابراین خاصیت طراحی است و نه تصادف یک اجرا.

یک نکته‌ی دیگر در این جدول نیاز به توضیح صادقانه دارد. مسیر «ویژگی خام» که ۲٬۰۴۸ ویژگی شبکه را به‌همراه سن مستقیماً به طبقه‌بند می‌دهد، ضعیف‌ترین نتیجه را داد. وسوسه‌انگیز است که این را شاهدی بر برتری مفهوم «شکاف سن مغز» بدانیم، اما چنین نتیجه‌گیری نادرست است. علت واقعی **بیش‌برازش** است: ۲٬۰۴۸ ویژگی برای ۶۲۱ نفر بسیار زیاد است و گلوگاه هفت‌عددی در اینجا نقش یک منظم‌ساز قوی را بازی می‌کند، نه نقش یک مفهوم زیستی برتر.

---

## بخش ۵: بدون وزن‌های از پیش آموزش‌دیده، هیچ‌کدام از این‌ها کار نمی‌کند

بخش پیش نشان داد که گلوگاه تشریحی جواب می‌دهد، اما نگفت که چرا همان گلوگاه در نخستین تلاش‌های ما جواب نداده بود. پاسخ در جایی است که به‌آسانی از قلم می‌افتد: **وزن اولیه‌ی شبکه**.

## ۵–۱ شبکه‌ی آموزش‌دیده از صفر اصلاً یاد نمی‌گیرد

نخستین شبکه‌ی سه‌بعدی که روی ADNI آموزش دادیم، در همه‌ی حالت‌ها روی شانس ماند (AUC میان ۰٫۴۸ تا ۰٫۵۳). نکته‌ی تعیین‌کننده این بود که این عدد **پایین‌تر از PCA خطی روی همان داده** بود. شبکه‌ای که به یک روش خطی ساده می‌بازد، یاد نگرفته است.

علت هم روشن بود: مدل سن در هر فولد تنها حدود ۳۱۳ حجم برای آموزش در اختیار داشت. یک شبکه‌ی سه‌بعدی با میلیون‌ها پارامتر از این مقدار داده چیزی نمی‌آموزد.

این نتیجه را **به‌عنوان شاهدی بر بی‌فایده بودن تصویر ثبت نکردیم**، زیرا گزاره‌ای درباره‌ی اندازه‌ی نمونه است و نه درباره‌ی تصویر. اما راه حل را نشان داد: اگر داده کم است، باید دانش را از جای دیگری آورد.

## ۵–۲ دو آزمون کنترلی: وزن اولیه چقدر ارزش دارد؟

برای آنکه ارزش وزن‌های از پیش آموزش‌دیده را حدس نزنیم بلکه اندازه بگیریم، دو بازوی کنترلی طراحی کردیم که با بازوهای اصلی **در همه چیز یکسان‌اند جز یک عامل**:

| بازو | وزن اولیه | تنظیم دقیق | میانگین همبستگی |
|---|---|---|---|
| ResNet-50 | از پیش آموزش‌دیده | دارد | **۰٫۵۰۴** |
| ResNet-50 | تصادفی | دارد | ۰٫۳۷۷ |
| ViT-S | از پیش آموزش‌دیده | ندارد (منجمد) | ۰٫۳۷۹ |
| ViT-S | از پیش آموزش‌دیده | دارد | ۰٫۴۶۲ |

از این جدول دو عدد بیرون می‌آید:

**ارزش وزن‌های از پیش آموزش‌دیده: ۰٫۱۲۷+ ارزش تنظیم دقیق روی همان وزن‌ها: ۰٫۰۸۳+**

و یک مشاهده‌ی مهم‌تر: بازوی «از صفر» (۰٫۳۷۷) و بازوی «منجمد» (۰٫۳۷۹) عملاً یکسان‌اند. یعنی **وزن‌های از پیش آموزش‌دیده‌ای که نتوان آن‌ها را تطبیق داد، تقریباً به اندازه‌ی نداشتن آن‌ها ارزش دارند.** هر دو مؤلفه لازم‌اند و هیچ‌کدام به‌تنهایی کافی نیست.

همین الگو را در مقیاس بزرگ‌تر نیز دیدیم. با استفاده از همان ۳٬۲۸۶ اسکن، سه حالت را مقایسه کردیم:

| بازنمایی | میانگین همبستگی |
|---|---|
| بدون وزن از پیش آموزش‌دیده (مؤلفه‌های اصلی) | ۰٫۳۱۷ |
| وزن از پیش آموزش‌دیده، منجمد | ۰٫۵۰۷ |
| وزن از پیش آموزش‌دیده، تنظیم‌شده | **۰٫۶۸۲** |

باید اضافه کرد که دو ردیف آخر این جدول کاملاً هم‌شرایط نیستند (بازوی تنظیم‌شده از برش‌های بیشتری استفاده می‌کند)، بنابراین اعداد دقیقِ اختلاف را باید از جدول کنترلی بالا گرفت و این جدول را تنها به‌عنوان تأیید جهت‌گیری خواند.

## ۳–۵ کدام معماری؟ سه نتیجه‌ی غیرمنتظره

هفت معماری را روی داده و زمان‌بندی یکسان مقایسه کردیم:

| معماری | میانگین همبستگی | خطای تخمین سن |
|---|---|---|
| ResNet-50 | **۰٫۵۰۴** | ۴٫۳۷ سال |
| ViT-S/16 | ۰٫۴۶۲ | **۴٫۲۴ سال** |
| ConvNeXt-T | ۰٫۴۵۴ | ۴٫۳۲ سال |
| ViT-B/16 | ۰٫۴۲۶ | ۴٫۴۳ سال |
| DINOv2-S | ۰٫۳۳۹ | ۴٫۷۸ سال |

سه نکته در این جدول شایان توجه است. نخست آنکه **شبکه‌های کانولوشنی از همه‌ی ترنسفورمرها بهتر عمل کردند**؛ با حدود دو هزار تصویر پزشکی، پیش‌فرض‌های ساختاری کانولوشن هنوز ارزش دارند. دوم آنکه **ViT بزرگ‌تر از ViT کوچک‌تر بدتر بود** (۰٫۴۲۶ در برابر ۰٫۴۶۲)، که با اندازه‌ی نمونه سازگار است: ظرفیت بیشتر در داده‌ی کم ضرر می‌زند.

سوم آنکه DINOv۲ در انتهای جدول قرار گرفت، با اینکه یکی از قوی‌ترین استخراج‌کننده‌های ویژگی در بینایی کامپیوتر است. اما این نتیجه را **معتبر نمی‌دانیم**: این مدل با وصله‌های ۱۴ پیکسلی طراحی شده و ما اندازه‌ی ورودی ۲۲۴ را بر آن تحمیل کردیم، که موجب بازنمونه‌گیری بردارهای موقعیت می‌شود. این را به‌عنوان «آزمایش‌نشده» ثبت می‌کنیم و نه به‌عنوان قضاوتی درباره‌ی DINOv۲.

## ۴–۵ یک درس روش‌شناختی: غربالگری کم‌آموزش، معماری اشتباه را انتخاب می‌کند

جدول بالا از یک غربالگری سریع به‌دست آمد: یک فولد و شش دوره‌ی آموزش. بر اساس آن، ResNet-50 را برنده اعلام کردیم و اجرای کامل را با همان انجام دادیم. نتیجه از اجرای پیشین **بدتر** شد.

| | **ResNet-18**، ۱۴ دوره | **ResNet-50**، ۸ دوره | **ResNet-18**، ۲۰ دوره |
|---|---|---|---|
| میانگین همبستگی | ۰٫۶۱۴ | ۰٫۵۹۹ | **۰٫۶۸۲** |
| تشخیص آلزایمر | ۰٫۸۲۴ | ۰٫۷۸۲ | **۰٫۸۳۶** |

وقتی همان خط لوله را با بودجه‌ی آموزشی بیشتر (۲۰ دوره و ۱۲ برش به‌جای ۸ دوره و ۶ برش) اجرا کردیم، بهترین نتیجه‌ی کل کار حاصل شد.

> **درس:** غربالگری باید با همان بودجه‌ی آموزشی‌ای انجام شود که در اجرای نهایی به‌کار می‌رود. غربالگریِ کم‌آموزش اندازه می‌گیرد کدام مدل **سریع‌تر** یاد می‌گیرد، نه کدام مدل **بهتر** تمام می‌کند. در کار ما، تعداد دوره‌ها و برش‌ها تأثیری بیشتر از انتخاب معماری داشت.

---

# بخش ۶: آزمون سخت‌تر — مدلی که در یک اسکن دقیق است، می‌تواند نسبت به تغییر نابینا باشد

تا اینجا هر چه سنجیدیم **مقطعی** بود: یک اسکن، یک تشخیص. اما مهم‌ترین یافته‌ی گزارش سوم مقطعی نبود؛ آنجا نشان دادیم که **سرعت پیری مغز** اطلاعاتی فراتر از یک اندازه‌گیری منفرد دارد و به پیش‌بینی تبدیل MCI به دمانس کمک می‌کند. اگر قرار است همه‌چیز از پیکسل بازسازی شود، آن یافته نیز باید بازسازی شود.

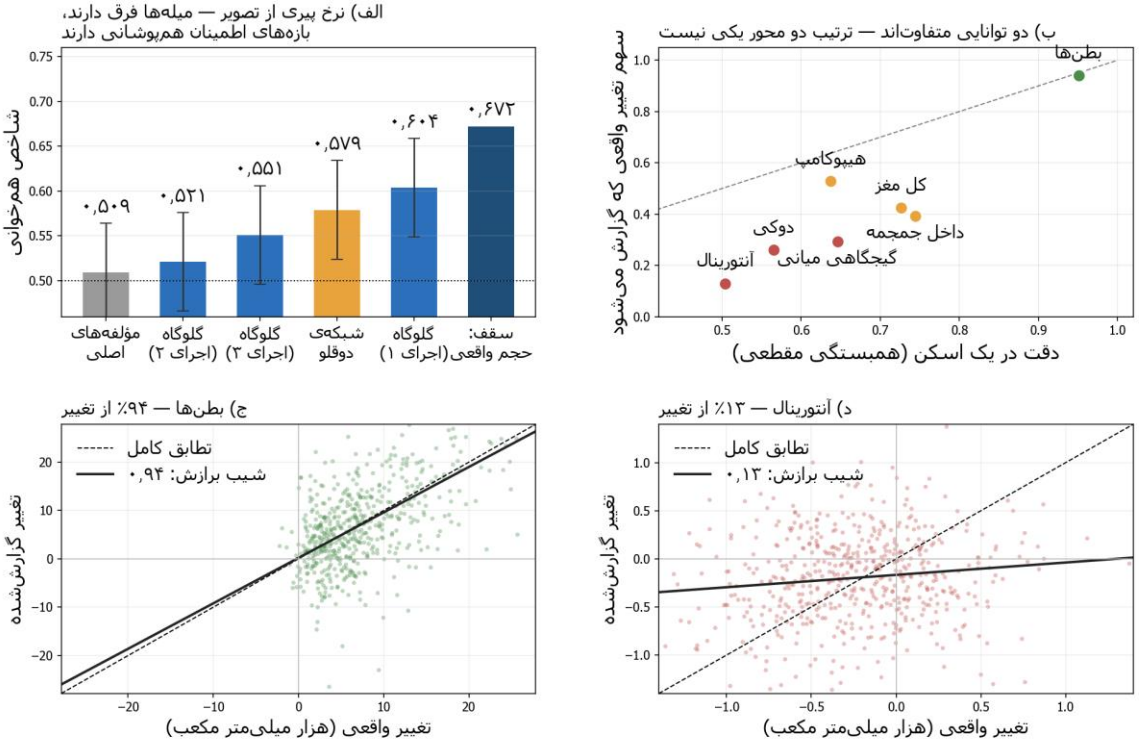
## ۶-۱ نرخ پیری از روی تصویر بازیابی نمی‌شود

با همان طرح نشانه‌گذاری (landmark) گزارش سوم — یعنی برآورد سرعت فقط از اسکن‌های دو سال نخست و شمارش تبدیل‌ها فقط پس از آن — نتیجه چنین شد:

| منبع نرخ | شاخص هم‌خوانی |
|---|---|
| مؤلفه‌های اصلی روی وکسل‌ها | ۰٫۵۰۹ |
| گلوگاه، اجراهای مختلف | ۰٫۵۲۱ تا ۰٫۶۰۴ |
| **سقف: نرخ از حجم‌های واقعی** | **۰٫۶۷۲ تا ۰٫۶۸۴** |

در حالی که همان گلوگاه در تشخیص مقطعی ۷۴ درصد سیگنال را بازیابی می‌کرد، در سنجش سرعت به‌سختی از شانس فاصله می‌گیرد. این تضاد، نکته‌ی اصلی این بخش است.

## ۲-۶ تشخیص: تصویر فقط بخشی از تغییر واقعی را گزارش می‌کند




**شکل ۳ — تضعیف طولی. الف) نرخ پیری حاصل از تصویر در اجراهای مختلف، همراه با بازه‌ی عدم‌قطعیت اندازه‌گیری؛ میله‌ها متفاوت‌اند اما بازه‌ها هم‌پوشانی دارند. ب) دقت مقطعی در برابر حساسیت به تغییر؛ اگر این دو یک توانایی بودند، نقاط روی خط‌چین می‌نشستند. ج و د) داده‌ی خام پشت این کمیت برای بهترین و بدترین ناحیه؛ شیب خط برازش همان میزان تضعیف است.**

برای فهمیدن علت، کمیت تازه‌ای تعریف کردیم. برای هر فرد که دست‌کم دو اسکن با فاصله‌ی زمانی معنادار داشت، تغییر واقعی حجم (بر اساس FreeSurfer) را با تغییری که شبکه گزارش می‌کند مقایسه کردیم. شیب این رابطه می‌گوید چه کسری از تغییر واقعی اصلاً دیده می‌شود.

| ناحیه | همبستگی مقطعی | درصد تغییر واقعی که گزارش می‌شود |
|---|---|---|
| بطن‌ها | ۰٫۹۵ | **٪۹۴** |
| کل مغز | ۰٫۷۳ | ٪۴۳ |
| حجم داخل جمجمه | ۰٫۷۴ | ٪۳۹ |
| هیپوکامپ | ۰٫۶۴ | ٪۵۳ |

| | | |
|---|---|---|
| گیجگاهی میانی | ۰٫۶۵ | ٪۲۹ |
| شکنج دوکی | ۰٫۵۷ | ٪۲۶ |
| **قشر آنتورینال** | ۰٫۵۰ | **٪۱۳** |

این جدول دو چیز می‌گوید. نخست آنکه حتی بهترین مدل ما به‌طور میانگین تنها حدود **۴۲ درصد** از تغییر واقعی را گزارش می‌کند؛ نرخی که از چنین اعدادی ساخته شود، **پیش از آنکه به هیچ مدل بقایی برسد، به‌سمت صفر جمع شده است**.

دوم و مهم‌تر آنکه این کمیت از دقت مقطعی **قابل پیش‌بینی نیست**. حجم داخل جمجمه با همبستگی ۰٫۷۴ تنها ۳۹ درصد تغییر را گزارش می‌کند، در حالی که هیپوکامپ با همبستگی پایین‌تر ۰٫۶۴ به ۵۳ درصد می‌رسد. ترتیب دو ستون یکی نیست، یعنی **دقت در یک اسکن و حساسیت به تغییر، دو توانایی متفاوت‌اند.**

و بار دیگر، بدترین عدد جدول متعلق به قشر آنتورینال است — همان جایی که آسیب آلزایمر از آن آغاز می‌شود.

## ۳-۶ آیا می‌توان شبکه را به تغییر حساس کرد؟

اگر مشکل این است که هیچ‌جای خط لوله از شبکه نخواسته‌ایم به تغییر حساس باشد، راه‌حل طبیعی آن است که مستقیماً تغییر را هدف آموزش قرار دهیم. دو نسخه از این ایده را آزمودیم.

**نسخه‌ی ساده** — رگرسیون تفاضل حجم بر تفاضل ویژگی‌های منجمد — کاملاً فروپاشید (شیب تقریباً صفر). علت روشن است: ویژگی‌های منجمد عمدتاً «هویت فرد» را کد می‌کنند، پس تفاضل دو مراجعه‌ی یک فرد تقریباً همه‌ی اطلاعات مفید را حذف می‌کند و نویز باقی می‌ماند.

**نسخه‌ی کامل** — یک شبکه‌ی دوقلو (siamese) که هر دو اسکن را هم‌زمان می‌بیند و از روی هر دو، تغییر را پیش‌بینی می‌کند — نتیجه‌ی ظریف‌تری داد:

| | همبستگی با تغییر واقعی | شیب گزارش تغییر |
|---|---|---|
| مدل معمولی (تفاضل پیش‌بینی‌ها) | ۰٫۲۴۵ | ۰٫۴۲۴ |
| شبکه‌ی دوقلو | **۰٫۳۰۱** | ۰٫۱۸۹ |

شبکه‌ی دوقلو تغییر را **بهتر رتبه‌بندی می‌کند** ولی آن را **کوچک‌تر گزارش می‌کند**. اینجا متوجه شدیم که شیب، معیار مناسبی برای این کاربرد نیست: مدل بقای Cox افراد را رتبه‌بندی می‌کند و مقیاس در آن حذف می‌شود. بنابراین آنچه اهمیت دارد همبستگی است، نه شیب. با این تصحیح، نرخ حاصل از شبکه‌ی دوقلو به ۰٫۵۷۹ رسید.

یک نکته‌ی مربوط به پیشینه: آموزش شبکه روی جفت‌های طولی ایده‌ی تازه‌ای نیست و در ادبیات سابقه دارد. تفاوت کار ما در کمیتی است که **اندازه می‌گیریم** — یعنی میزان تضعیف — و نه در خودِ معماری.

## ۶-۴ خطاهایی که در کار خودمان یافتیم

سه خطا در این مسیر پیدا کردیم که هر سه اعدادی تولید کرده بودند که کاملاً باورپذیر به‌نظر می‌رسیدند.

**نخست، معیار «درصد بازیابی»**. در ابتدا این کمیت را به‌صورت نسبت ساده‌ی دو AUC حساب می‌کردیم. نتیجه برای سه وظیفه‌ی کاملاً متفاوت اعداد ۸۶٫۴ و ۸۶٫۷ و ۸۶٫۴ درصد بود — یکنواختی‌ای که خودش باید هشداردهنده می‌بود. علت این است که کف AUC صفر نیست بلکه ۰٫۵ است، و نسبت ساده این کف را نادیده می‌گیرد. روی مقیاس درست، همان سه عدد ۷۱٫۵ و ۶۳٫۹ و ۵۹٫۴ درصدند؛ یعنی **بازیابی با سخت‌تر شدن وظیفه افت می‌کند**، روندی که معیار نادرست کاملاً پنهان کرده بود.

**دوم، نرمال‌سازی شدت**. همان‌طور که در بند ۲-۲ توضیح داده شد، در نخستین نسخه بر میانگین تقسیم می‌کردیم و این کار سیگنال آتروفی را حذف می‌کرد.

**سوم و مهم‌ترین: مقایسه‌هایی که هرگز از نظر آماری معنادار نبودند**. در جریان همین بخش، تفاوت میان اجراهای مختلف در نرخ (اعداد ۰٫۵۲۱ تا ۰٫۶۰۴) را جدی گرفتیم و دو آزمایش کامل را صرف توضیح آن کردیم. سپس بوت‌استرپ در سطح فرد را اجرا کردیم:

| | مقدار |
|---|---|
| اختلاف دو اجرا | +۰٫۰۴۹ |
| بازه‌ی اطمینان ۹۵٪ | از −۰٫۰۱۹ تا +۰٫۱۱۵ |
| مقدار p | ۰٫۱۴۱ |

| | |
|---|---|
| پهنای بازه‌ی اطمینان یک اجرا | ۰٫۱۱۰ |

با ۲۰۳ فرد و ۱۲۳ رویداد، شاخص هم‌خوانی را نمی‌توان دقیق‌تر از حدود ۰٫۰۵۵± تعیین کرد. **تمام تفاوت‌هایی که تفسیر کرده بودیم درون یک باند نویز قرار می‌گیرند.** آن تفسیرها را پس می‌گیریم.

نکته‌ی آموزنده این است که ما همین آزمون را در گزارش سوم **به‌درستی** روی ادعای اصلی اجرا کرده بودیم و همان‌جا نشان داده بودیم که ادعای «نرخ بهتر از مقدار است» از صفر عبور می‌کند؛ اما آن را برای مقایسه‌ی اجراهای خودمان به‌کار نبردیم. از این پس، هیچ مقایسه‌ای میان دو اجرا بدون بازه‌ی اطمینان گزارش نمی‌شود.

### ۶-۵ آنچه پس از این تصحیح باقی می‌ماند

با کنار گذاشتن تفاوت‌های درون باند نویز، دو گزاره برجا می‌ماند و هر دو محکم‌اند:

**۱.** نرخ حاصل از تصویر در همه‌ی پنج اجرا میان ۰٫۵۲ و ۰٫۶۰ می‌ماند، در حالی که نرخ حاصل از حجم‌های واقعی ۰٫۶۷ تا ۰٫۶۸ است. **این فاصله بزرگ و پایدار است** و یافته‌ی واقعی همین است، نه تفاوت میان اجراها.

**۲.** تضعیف، اندازه‌گیری‌شده و تکرارپذیر است و با تغییر هدف آموزش از میان نمی‌رود. بنابراین ویژگیِ **بازنمایی** است و نه ویژگیِ نحوه‌ی طرح مسأله.

---

## بخش ۷: جمع‌بندی، مقایسه با ادبیات، و مسیر پیش رو

### ۷-۱ آیا آنچه در ادبیات گزارش شده بازتولید شد؟

| وظیفه | اعداد منتشرشده با اعتبارسنجی درست | نتیجه‌ی ما |
|---|---|---|
| آلزایمر در برابر سالم، از حجم‌ها | ۰٫۹۰ تا ۰٫۹۵ | **۰٫۹۵۲** |
| آلزایمر در برابر سالم، از تصویر | ۰٫۸۵ تا ۰٫۹۰ | ۰٫۸۳۶ |
| MCI در برابر سالم | ۰٫۷۰ تا ۰٫۷۵ | **۰٫۷۰۰** |

| | | |
|---|---|---|
| پیش‌بینی تبدیل MCI به دمانس | ۰٫۷۰ تا ۰٫۸۰ | **۰٫۷۱۵** |

سه ردیف از چهار ردیف در محدوده‌ی منتشرشده قرار می‌گیرند و ردیف تصویری اندکی پایین‌تر است.

در اینجا یک نکته‌ی مهم باید ذکر شود. بسیاری از مقالات، AUC هایی میان ۰٫۹۵ تا ۰٫۹۹ برای تشخیص آلزایمر از تصویر خام گزارش می‌کنند که با اعداد ما فاصله‌ی زیادی دارد. مرور نظام‌مند Wen و همکاران (۲۰۲۰، مجله‌ی Medical Image Analysis) نشان داد که بخش بزرگی از آن اعداد ناشی از **نشت داده** است؛ یعنی اسکن‌های یک فرد میان مجموعه‌ی آموزش و آزمون تقسیم شده‌اند. وقتی همان مقالات با تقسیم درست در سطح فرد بازتولید می‌شوند، اعداد به همان محدوده‌ی ۰٫۸۵ تا ۰٫۹۰ بازمی‌گردند. تمام اعداد این گزارش از ابتدا با تقسیم در سطح فرد به‌دست آمده‌اند.

## ۲-۷ کدام نتیجه‌ی گزارش سوم باید بازنویسی شود؟

گزارش سوم با این جمله بسته شد که هرگز از تصویر استفاده نکرده‌ایم. آن محدودیت اکنون بسته شده است، اما پاسخ همان چیزی نیست که در نگاه نخست به‌نظر می‌رسید. صورت‌بندی درست چنین است:

> **تصویر خام در این مقیاس کمکی نمی‌کند؛ اما تصویری که از مجرای یک گلوگاه تشریحی نظارت شود، بخش عمده‌ی سیگنال را بازمی‌گرداند. محدودیت در بازنمایی بود، نه در اطلاعات.**

این نتیجه از نظر منطقی هم ناگزیر بود، زیرا حجم‌ها از روی همان تصویر محاسبه می‌شوند.

افزون بر این، در جریان همین کار، ادعای اصلی گزارش سوم را نیز بازآزمایی کردیم. آن ادعا این بود که سرعت پیری مغز چیزی به یک اندازه‌گیری منفرد می‌افزاید. با اعتبارسنجی متقاطع و بوت‌استرپ در سطح فرد، عدد ۰٫۰۴۸+ به‌صورت **۰٫۰۵۲+ با بازه‌ی اطمینان ۰٫۰۲۹+ تا ۰٫۰۷۷+** بازتولید شد؛ یعنی ادعا برقرار است. اما یک محدودیت تازه هم آشکار شد: سرعت پیری مغز از **سرعت** آتروفی هیپوکامپ بهتر عمل می‌کند، ولی برتری آن بر **یک‌بار اندازه‌گیری** هیپوکامپ از نظر آماری قطعی نیست. این سخت‌ترین خط پایه‌ای است که تاکنون با آن روبه‌رو شده‌ایم و باید در ادامه‌ی کار جدی گرفته شود.

## ۷-۳ سهم ما چیست و چه چیزی سهم ما نیست

برای آنکه در ارزیابی کار خودمان دچار اغراق نشویم، ادعاهای احتمالی را جداگانه بررسی کردیم:

**آنچه سهم ما نیست.** کف نویز شکاف سن مغز را با اسکن‌های تکراری هم‌جلسه اندازه گرفتیم و به حدود ۱٫۹ سال رسیدیم. جست‌وجوی ادبیات نشان داد این کار پیش‌تر و با طراحی قوی‌تری انجام شده است. بنابراین آن را به‌عنوان **اعتبارسنجی خط لوله‌ی خودمان** گزارش می‌کنیم و نه به‌عنوان یافته‌ی تازه. همچنین آموزش شبکه روی جفت‌های طولی سابقه‌ی منتشرشده دارد.

**آنچه احتمالاً سهم ماست.** اندازه‌گیری میزان تضعیف در حجم‌های پیش‌بینی‌شده از تصویر، و نشان دادن اینکه این کمیت از دقت مقطعی قابل پیش‌بینی نیست. کارهای منتشرشده در این حوزه بر **سازگاری** روش‌های قطعه‌بندی متمرکزند و شیب تضعیف را کمّی نمی‌کنند. این سهمی باریک است و نه یک تغییر پارادایم؛ خودِ مفهوم تضعیف در آمار کلاسیک شناخته‌شده است.

**آنچه کمّی کرده‌ایم.** ارزش وزن‌های از پیش آموزش‌دیده (+۰٫۱۲۷)، ارزش تنظیم دقیق (+۰٫۰۸۳) و برتری گلوگاه بر آموزش سرتاسری (+۰٫۱۱۲). این اعداد معمولاً در مقالات گزارش نمی‌شوند، زیرا نویسندگان مستقیماً بهترین پیکربندی را ارائه می‌کنند.

## ۷-۴ محدودیت‌ها

**نخست، اندازه‌ی نمونه برای سنجش سرعت کافی نیست.** با ۲۰۳ فرد و ۱۲۳ رویداد، پهنای بازه‌ی اطمینان شاخص هم‌خوانی حدود ۰٫۱۱ است. رتبه‌بندی مدل‌های تصویری بر اساس نرخ، با این حجم داده ممکن نیست.

**دوم، حلقه‌ی ضعیف همچنان قشر آنتورینال است.** این ناحیه هم در بازتولید مقطعی (۰٫۵۰) و هم در گزارش تغییر (۱۳ درصد) بدترین عملکرد را دارد، و دقیقاً همان جایی است که آسیب آلزایمر از آن آغاز می‌شود.

**سوم، کار تصویری عمدتاً بر یک کوهورت استوار است.** آزمایش‌های اصلی روی ADNI انجام شد و OASIS تنها برش‌های دوبعدی دارد. تکرار روی یک کوهورت مستقل با حجم‌های سه‌بعدی انجام نشده است.

**چهارم، ورودی شبکه برش‌های دوبعدی از حجم سه‌بعدی است.** این انتخاب امکان استفاده از مدل‌های از پیش آموزش‌دیده را فراهم کرد، اما بخشی از اطلاعات فضایی را دور می‌ریزد.

## ۵-۷ مسیر پیشنهادی برای ادامه

سه مسیر، به ترتیب اولویت:

**یک، تقویت حلقه‌ی ضعیف.** چون قشر آنتورینال هم مهم‌ترین و هم ضعیف‌ترین ناحیه است، منطقی است که به‌جای کل مغز، یک برش موضعی با رزولوشن بالاتر از ناحیه‌ی گیجگاهی-میانی به شبکه داده شود. این آزمایش مستقیم و کم‌هزینه است.

**دو، افزایش تعداد رویدادها.** برای آنکه بتوان درباره‌ی سرعت پیری از روی تصویر ادعای معناداری کرد، به کوهورت بزرگ‌تر یا پیگیری طولانی‌تر نیاز است. بدون آن، هر مقایسه‌ای در باند نویز باقی می‌ماند. هرچند هنوز در این خصوص دیتاستی پیدا نکرده‌ام.

**سه، آموزش با آگاهی از تضعیف.** اکنون می‌دانیم که شبکه تغییر را کوچک‌تر از واقع گزارش می‌کند و می‌دانیم این میزان برای هر ناحیه متفاوت است. می‌توان این ضریب را اندازه گرفت و پیش از محاسبه‌ی نرخ، تصحیح کرد.

در پایان لازم است یک نکته تصریح شود. هیچ‌یک از نتایج این گزارش، اعداد منتشرشده در مقالاتی را که با ده‌ها هزار نفر آموزش دیده‌اند جابه‌جا نمی‌کند. فاصله‌ی ما تا آن اعداد عمدتاً **مسأله‌ی داده است و نه مسأله‌ی روش**. آنچه این گزارش فراهم می‌کند چیز دیگری است: اندازه‌گیری اینکه در این مقیاس، هر مؤلفه‌ی طراحی دقیقاً چقدر می‌ارزد — و ثبت صادقانه‌ی مسیرهایی که آزمودیم و به نتیجه نرسیدند.